

Заметка об оценке больших языковых моделей

Е. В. Проверова

Краткая фикстура Ainiux: одна страница кириллицы про LLM

Аннотация

Большая языковая модель оценивается не одним числом. Перплексия на удерживаемом корпусе измеряет правдоподобие токенов, но слабо коррелирует с полезностью ответа. Человеческие шкалы — полнота, фактичность, отказ от вредных инструкций — требуют протокола и нескольких аннотаторов. Автоматические судьи ускоряют цикл, однако сами являются моделями и наследуют их смещения.

1. Что фиксировать в отчёте

Минимальный отчёт об оценке LLM должен называть корпус, язык (здесь русский), длину контекста и запрет на утечку тестовых промптов в обучение. Имеет смысл разделить закрытые знания и умения следовать формату. Смешение латиницы и кириллицы типично: аббревиатура LLM, метрика BLEU, модель GPT рядом со словами «обучение» и «языковая модель». Если извлечение PDF сохраняет обе письменности, последующий Markdown остаётся читаемым.

Практическое правило для этой одностраничной заметки: искать строки «большая языковая модель», «перплексия», «оценка» и «обучение». Фикстура не является научной публикацией и не цитирует чужие результаты как собственные.