

Краткий обзор архитектуры Transformer для языкового моделирования

А. И. Тестов, М. П. Примернова

Фикстурный институт вычислительной лингвистики — тестовая заметка Ainiux

Аннотация

В этой короткой заметке суммируются основные элементы архитектуры Transformer, предложенной для задач последовательности. Самовнимание (self-attention) позволяет каждому токenu учитывать контекст всего предложения без рекуррентного шага. Модели BERT и GPT показывают, что один и тот же блок внимания масштабируется как для кодирования, так и для авторегрессионной генерации. Текст написан по-русски, чтобы проверить извлечение кириллицы из PDF.

1. Самовнимание

Механизм внимания сопоставляет запросы, ключи и значения. Для токена i вес связи с токеном j пропорционален сходству запроса i и ключа j . После нормализации softmax взвешенная сумма значений даёт новое представление. Многоголовость (multi-head) повторяет это преобразование несколько раз в разных подпространствах, затем конкатенирует результаты. Для языкового моделирования это заменяет медленный скрытый путь RNN и упрощает параллельное обучение.

Позиционная информация не содержится в самом внимании, поэтому к эмбедингам добавляют синусоидальные или обучаемые позиционные коды. Без них перестановка слов не меняла бы представление, что неприемлемо для русского порядка слов и свободной морфологии. На практике достаточно относительных смещений, чтобы модель отличала «обучение с учителем» от переставленных фрагментов.

2. Кодировщик, декодировщик и таблица ориентиров

Классический Transformer состоит из стека кодировщика и стека декодировщика. Кодировщик видит всю входную последовательность; декодировщик посещает уже сгенерированные слева токены и выходы кодировщика. Предобучение BERT маскирует токены внутри предложения, а GPT предсказывает следующий токен. Оба подхода опираются на тот же блок внимания и на слой нормализации.

Для русского языка морфология увеличивает словарь подслов: приставки, суффиксы и окончания дают больше редких кусков, чем в английском. Поэтому длина контекста в токенах не равна числу слов. Это важно при сравнении перплексии между корпусами. Обучение на смеси новостей, художественной прозы и кода обычно снижает ошибку на смешанных промптах, но может размыть стиль. Фикстура не утверждает новых эмпирических результатов: она лишь держит термины «трансформер» и «внимание» рядом с латинскими именами моделей.

Регуляризация стандартна: dropout на эмбедингах и внутри блока, отсечение градиента, разогрев шага обучения. Нормализация слоя стабилизирует глубокий стек. Если убрать остаточные связи, качество падает быстрее, чем при умеренном сужении числа голов. Практик часто начинает с малого числа блоков, затем наращивает глубину, когда упирается в недообучение. Для извлечения текста из этого PDF достаточно, чтобы абзац оставался связным кириллическим текстом без

потери ударений на «ё» в словах вроде «ещё», если они встретятся.

Модель	Роль	Замечание
BERT	кодировщик	маскированное языковое моделирование
GPT	декодировщик	авторегрессия, генерация текста
Transformer	полный стек	машинный перевод, внимание без RNN

Вывод. Для тестового извлечения достаточно сохранить кириллические корни «трансформер», «внимание», «языковая модель», «обучение» и латинские имена BERT и GPT. Эта заметка намеренно короткая: две страницы A4 без рисунков.